INFORME TÉCNICO

Análisis de Sentimientos con Deep Learning

Sistema de Clasificación de Sentimientos y Chatbot Inteligente

---

Docente: Mg. Joel Orellana
Materia: Deep Learning
Grupo: 3

Integrantes:
César Bladimir Romero Rugamas
Guillermo Ulises Palacios Flores
Walter Alexander Salguero Rodríguez

Abril 2026

1. Introducción y Descripción del Problema

El análisis automático de sentimientos es uno de los problemas fundamentales del Procesamiento de Lenguaje Natural (NLP). En un entorno donde los usuarios generan millones de opiniones diarias en redes sociales, plataformas de reseñas y sistemas de feedback, la capacidad de clasificar automáticamente estas opiniones como positivas o negativas tiene un valor comercial y académico considerable.

El presente proyecto final del curso de Deep Learning construye progresivamente un sistema completo de análisis de sentimientos, partiendo desde un modelo baseline clásico (TF-IDF + MLP) hasta un chatbot inteligente que combina clasificación con generación de respuestas empáticas. El desarrollo se estructura en cinco etapas incrementales, cada una superando las limitaciones arquitectónicas de la anterior.

1.1 Definición del Problema

El problema central es la clasificación binaria de texto: dado un texto de entrada (reseña de película, comentario de usuario), el sistema debe determinar si el sentimiento expresado es positivo o negativo. Formalmente:

- Entrada: texto en lenguaje natural (reseña, comentario)
- Salida: etiqueta binaria {positivo, negativo} + nivel de confianza
- Objetivo extendido: generar una respuesta empática condicionada al sentimiento detectado

1.2 Motivación y Justificación

Este problema presenta desafíos técnicos relevantes que justifican el uso de técnicas de Deep Learning: la presencia de sarcasmo e ironía, negaciones complejas ("not bad at all"), dependencias de largo alcance en textos extensos, y vocabulario especializado por dominio. Estas características hacen insuficientes los enfoques clásicos de bag-of-words y requieren modelos capaces de capturar contexto semántico profundo.

2. Descripción del Dataset

2.1 Dataset Principal: IMDb Large Movie Review Dataset

El dataset utilizado es el IMDb Large Movie Review Dataset, un benchmark estándar y ampliamente citado en NLP para tareas de clasificación de sentimientos. Sus características principales son:

Atributo	Detalle
Nombre	IMDb Large Movie Review Dataset
Fuente original	Stanford AI Lab — Maas et al. (2011)
Tamaño	50,000 reseñas de películas en inglés
Variables	review (texto libre) + sentiment (etiqueta)
Clases	positive (25,000) / negative (25,000)
Balance	Perfectamente balanceado — 50% por clase
Tipo de texto	Reseñas largas, vocabulario formal e informal, HTML residual
Benchmark	Estado del arte ~97.4% con BERT fine-tuned (Sun et al., 2019)

2.2 Análisis Exploratorio

El análisis de longitud de reseñas revela una distribución asimétrica hacia la derecha:

Clase	Media (palabras)	Mediana (palabras)	Mínimo	Máximo
POSITIVE	233	172	10	2,470
NEGATIVE	229	174	4	1,522

La distribución de clases es perfectamente balanceada (ratio = 1.000), lo que elimina sesgos de clase y permite entrenamiento sin técnicas adicionales de balanceo como oversampling o pesos de clase.

2.3 División del Dataset

Se utilizó una división estratificada 80%/20% con random_state=42 y stratify=y para garantizar que todas las etapas sean directamente comparables:

- Conjunto de entrenamiento: 40,000 reviews (20,000 positivas / 20,000 negativas)
- Conjunto de prueba: 10,000 reviews (5,000 positivas / 5,000 negativas)
- Para Etapa 3: se tomó una muestra de 20,000 reviews por restricciones de hardware en Google Colab

El mismo split se mantiene constante en todas las etapas, asegurando que las métricas sean comparables entre modelos.

3. Metodología y Arquitecturas

El proyecto sigue un enfoque incremental: cada etapa amplía el sistema anterior corrigiendo limitaciones específicas identificadas en el análisis de errores. El roadmap completo es:

Etapa	Arquitectura	Objetivo
Etapa 1	MLP + TF-IDF	Establecer baseline clásico
Etapa 2	BiLSTM + Word2Vec	Capturar dependencias secuenciales
Etapa 3	DistilBERT (Transformer)	Embeddings contextuales profundos
Etapa 4	DistilBERT + GPT-2	Generación de respuestas empáticas
Etapa 5	Fine-tuning parcial + LoRA + Despliegue	Optimización y producción

3.1 Etapa 1 — MLP + TF-IDF (Baseline)

Pipeline de preprocesamiento: conversión a minúsculas, eliminación de etiquetas HTML residuales con regex, eliminación de caracteres no alfabéticos, y normalización de espacios múltiples. Intencionalmente no se aplica stemming ni lemmatización para mantener simplicidad y velocidad.

Vectorización TF-IDF con 5,000 features (max_features=5000) para reducir dimensionalidad y eliminar términos extremadamente raros. División estratificada 80/20.

Arquitectura MLPClassifier: una capa oculta de 100 neuronas, activación ReLU, optimizador Adam, early stopping con 10% de validación interna. El modelo convergió en solo 13 de las 200 iteraciones máximas, con loss final de 0.1611.

3.2 Etapa 2 — BiLSTM + Word2Vec

Motivación: TF-IDF ignora completamente el orden de las palabras y las dependencias contextuales. La Etapa 2 introduce una arquitectura recurrente bidireccional para capturar estas relaciones.

Word2Vec Skip-gram entrenado sobre el corpus propio de 40,000 reviews de entrenamiento (vector_size=100, window=5, min_count=2). Vocabulario resultante: 56,908 palabras. El tokenizador de Keras construyó un vocabulario de 20,000 palabras con max_sequence_len=200 tokens.

Arquitectura BiLSTM: Embedding (20,000 vocab, 100d) → Bidirectional(LSTM(64 unidades)) → Dense(32, ReLU) → Dropout(0.3) → Dense(1, Sigmoid). Total: ~2,000,000 parámetros. EarlyStopping con patience=3 sobre val_loss, deteniendo a las 7 épocas.

3.3 Etapa 3 — DistilBERT (Transformer)

La Etapa 3 integra modelos Transformer preentrenados para superar las limitaciones de TF-IDF y Word2Vec. Se eligió DistilBERT-base-uncased por su balance óptimo entre rendimiento y costo computacional: 66M parámetros, 1.6x más rápido que BERT-base, conserva el 97% del rendimiento con el 40% menos de parámetros.

El tokenizador WordPiece maneja automáticamente palabras OOV mediante sub-tokens, tokens especiales [CLS] y [SEP], attention_mask, y truncamiento a 512 tokens. Fine-tuning con HuggingFace Trainer: 2 épocas, batch_size=8, AdamW lr=5e-5, eval_strategy='epoch'.

Como segundo modelo comparativo se evaluó cardiffnlp/twitter-roberta-base-sentiment-latest (RoBERTa fine-tuned en 124M tweets) en modalidad zero-shot y con fine-tuning, para estudiar la transferencia entre dominios.

3.4 Etapa 4 — Chatbot Híbrido (DistilBERT + GPT-2)

El objetivo de esta etapa es transformar el clasificador en un chatbot inteligente que genere respuestas empáticas. La arquitectura híbrida sigue el siguiente pipeline:

- Paso 1: DistilBERT clasifica el sentimiento del texto de entrada
- Paso 2: Se construye un prompt condicionado al sentimiento detectado
- Paso 3: GPT-2 small (117M params, preentrenado en WebText) genera la respuesta
- Paso 4: Post-procesamiento limpia y trunca la respuesta generada

Hiperparámetros de generación: temperature=0.75, top_p=0.92 (nucleus sampling), repetition_penalty=1.3, max_new_tokens=60. Para augmentación de datos, se usó T5-small (60M params) para generar paráfrasis de ejemplos difíciles (sarcasmo, negaciones complejas) identificados en el análisis de errores.

3.5 Etapa 5 — Fine-Tuning Eficiente + Despliegue

La Etapa 5 aplica dos estrategias de fine-tuning eficiente sobre DistilBERT y despliega el sistema vía Gradio:

- Fine-tuning parcial (head-only): congela distilbert.transformer (99.1% de parámetros), entrena únicamente pre_classifier y classifier (~592,130 parámetros, 0.9%)
- LoRA/PEFT (r=8, q_lin + v_lin, lora_alpha=32): inyecta matrices de adaptación de bajo rango sin modificar pesos originales. Solo 739,586 parámetros entrenables (1.09%), modelo base intacto
- Despliegue: interfaz Gradio con campo de texto, indicador de sentimiento con emoji y color, nivel de confianza, y ejemplos precargados

4. Experimentos y Comparación entre Modelos

4.1 Condiciones de Experimentación

Todos los experimentos se ejecutaron en Google Colab con GPU T4 (16 GB VRAM) para las etapas 3–5, y en CPU para las etapas 1–2. El mismo split estratificado (random_state=42, test_size=0.2) se mantuvo constante en todas las etapas para garantizar comparabilidad directa de métricas.

4.2 Configuración de Cada Experimento

Etapa	Modelo	Parámetros clave	Tiempo
E1	MLP + TF-IDF	100 neuronas, early stopping, 5K features	~30 seg
E2	BiLSTM + Word2Vec	64 unidades LSTM, dropout=0.3, 20K vocab, 200 tokens	~30 min
E3a	DistilBERT fine-tuned	2 épocas, batch=8, lr=5e-5, FP16	~30 min
E3b	RoBERTa-Twitter zero-shot	Sin fine-tuning en IMDb	—
E3c	RoBERTa-Twitter fine-tuned	2 épocas, batch=8, lr=5e-5	~65 min
E4	DistilBERT + GPT-2	GPT-2 small, temp=0.75, top_p=0.92	~1s/respuesta
E5a	DistilBERT FT parcial	Solo head, FP16, 2 épocas	~8 min
E5b	DistilBERT LoRA	r=8, lora_alpha=32, FP16, 3 épocas	~24 min

5. Resultados

5.1 Tabla Comparativa General — Todas las Etapas

Etapa	Modelo	Accuracy	F1 Macro	Parámetros	vs Etapa 1
E1	MLP + TF-IDF	89.09%	0.890	~500K	—
E2	BiLSTM + Word2Vec	88.63%	0.886	~2M	−0.46pp
E3	DistilBERT fine-tuned	92.10%	0.921	66M	+3.01pp
E3	RoBERTa-Twitter (zero-shot)	77.80%	0.774	125M	−11.29pp
E3	RoBERTa-Twitter (fine-tuned)	93.90%	0.939	125M	+4.81pp
E5	DistilBERT FT Parcial	86.29%	0.863	66M (1.5M ent.)	−2.80pp
E5	DistilBERT LoRA (r=8)	92.27%	0.923	66M (0.3M ent.)	+3.18pp

5.2 Análisis de Resultados por Etapa

Etapa 1 — Baseline sólido: El MLP con TF-IDF alcanzó 89.09% de accuracy con solo 13 iteraciones de entrenamiento. Esto demuestra que para textos largos con vocabulario explícito (como reseñas de IMDb), las features bag-of-words son suficientemente discriminativas. La convergencia rápida indica un espacio de decisión relativamente simple para este enfoque.

Etapa 2 — Regresión explicada: La BiLSTM con Word2Vec obtuvo 88.63%, una caída de 0.46pp respecto al baseline. Este resultado, aparentemente paradójico, tiene cuatro explicaciones técnicas concretas: (1) Word2Vec entrenado en corpus pequeño (40K reviews) produce embeddings de baja calidad; (2) early stopping agresivo con patience=3 detuvo el entrenamiento en la época 7, antes de que los embeddings se especializaran; (3) TF-IDF es extremadamente competitivo en clasificación binaria de texto largo; (4) la regularización puede haber sido demasiado conservadora.

Etapa 3 — Salto cualitativo: DistilBERT fine-tuned alcanzó 92.10% (+3.01pp sobre baseline) entrenando solo 2 épocas. La ventaja proviene del preentrenamiento masivo en 3,300M palabras y la atención bidireccional global que captura dependencias de largo alcance imposibles para TF-IDF. El análisis de errores reveló 190 FP y 126 FN; los errores restantes se concentran en sarcasmo explícito y negaciones complejas.

RoBERTa-Twitter en modo zero-shot obtuvo solo 77.80%, demostrando que la especialización en tweets (textos cortos y ruidosos) no generaliza bien a reseñas largas. Con fine-tuning alcanza 93.90%, pero a un costo de 2x parámetros y 2x tiempo de entrenamiento.

Etapa 5 — Fine-tuning eficiente: LoRA con solo 739K parámetros entrenables logra 92.27%, prácticamente igual a DistilBERT full fine-tuned de la Etapa 3 (92.10%). El fine-tuning parcial head-

only obtiene 86.29%, lo que confirma que el conocimiento del dominio está codificado en las capas transformer y no solo en la cabeza de clasificación.

5.3 Evaluación del Componente Generativo (Etapa 4)

Métrica	Valor	Interpretación
Distinct-1	0.515	Diversidad moderada de unigramas
Distinct-2	0.947	Alta diversidad de bigramas — respuestas variadas
Distinct-3	0.992	Muy alta diversidad de trigramas
Longitud media	18.1 ± 13.0 tokens	Respuestas concisas y completas
Tasa de fallback	3.3%	GPT-2 genera coherentemente el 96.7% del tiempo
Tiempo por respuesta	~1.14 seg	Aceptable para despliegue en tiempo real
Acc. casos difíciles	80% (8/10)	Buena robustez ante sarcasmo y negaciones

5.4 Análisis de Errores

El análisis cualitativo de 10 reseñas mal clasificadas por DistilBERT identificó los siguientes patrones:

- Sarcasmo/ironía (4 casos): "It's so bad it's good" — el modelo interpreta literalmente sin detectar la contradicción pragmática
- Negaciones complejas (2 casos): "not bad", "could have been worse" — difíciles incluso para BERT
- Conectores adversativos (2 casos): "but", "however" — el modelo a veces prioriza la primera cláusula
- Inversión sintáctica (1 caso): "Never have I seen such a wonderful..." — estructuras poco frecuentes en preentrenamiento
- Ambigüedad genuina (1 caso): reseñas con sentimiento verdaderamente mixto

6. Limitaciones y Trabajo Futuro

6.1 Limitaciones Identificadas

Limitación de hardware (Colab gratuito): Los modelos Transformer se entrenaron sobre una muestra de 20,000 reviews (en lugar de las 50,000 completas) por restricciones de memoria GPU. La literatura sugiere que con 15,000–20,000 ejemplos se alcanza el 95% del rendimiento máximo, por lo que esta limitación es aceptable pero introduce una subestimación del potencial real del modelo.

De igual manera se intentó correrlo el proyecto en local, pero PyTorch era compatible el CUDA sm_120 de la RTX 5050 que poseía y por miedo a entregar un mal resultado por la versión nightly se evito, de igual manera al forzar compatibilidad porque daba como resultado un flujo muy lento.

Truncamiento a 512 tokens: DistilBERT trunca reseñas que superan los 512 tokens (aproximadamente el 5% del corpus). Se pierde información del final de reseñas largas. Una solución sería usar estrategias de chunking o modelos de largo contexto como Longformer.

Error en fine-tuning de RoBERTa: En la implementación original de la Etapa 3, el fine-tuning de RoBERTa-Twitter conservó las 3 neuronas de salida originales (negativo, neutral, positivo) pero las etiquetas de IMDb se mapearon a índices 0 y 2, dejando la neurona neutral sin ejemplos de entrenamiento. Aunque el accuracy final (93.9%) no se vio severamente afectado, el rendimiento máximo alcanzable podría ser mayor con la corrección apropiada (num_labels=2).

Coherencia del componente generativo: GPT-2 sin fine-tuning en el dominio produce respuestas que, si bien son diversas, no siempre son semánticamente coherentes con el sentimiento detectado. Las respuestas tienden a divagar hacia temas no relacionados.

6.2 Trabajo Futuro

- Entrenamiento con el dataset completo (50,000 reviews) sobre GPU más potente para obtener métricas máximas con DistilBERT y RoBERTa
- Fine-tuning de GPT-2 sobre datos de diálogo empático para mejorar la coherencia del chatbot
- Implementación de estrategia de chunking para manejar reseñas mayores a 512 tokens sin truncamiento
- Incorporación de los 35 ejemplos sintéticos generados con T5 (sarcasmo y negaciones complejas) al conjunto de entrenamiento de Etapa 5 para mejorar robustez
- Evaluación sobre dataset de Twitter para validar generalización a texto corto y ruidoso
- Despliegue en producción con Cloud Run para disponibilidad permanente del chatbot
- Exploración de modelos de mayor contexto (Longformer, BigBird) para reseñas largas

7. Tabla Acumulada de Métricas (Opcional)

La siguiente tabla consolida todos los resultados obtenidos a lo largo del proyecto, permitiendo una comparación cuantitativa directa entre arquitecturas:

Etapa	Modelo	Acc.	Prec.	Rec.	F1	Params.	Tiempo	vs E1
E1	MLP + TF-IDF	0.896	0.898	0.896	0.896	~500K	30s	—
E2	BiLSTM+W2V	0.886	0.886	0.886	0.886	~2M	30 min	−0.46pp
E3	DistilBERT FT	0.921	0.921	0.921	0.921	66M	30 min	+2.50pp
E3	RoBERTa-FT	0.939	0.940	0.939	0.939	125M	65 min	+4.30pp
E5	FT Parcial	0.863	0.863	0.863	0.863	66M	8 min	−3.31pp
E5	LoRA (r=8)	0.923	0.923	0.923	0.923	66M*	24 min	+2.67pp

(*) LoRA: modelo base 66M intacto, solo 739K parámetros entrenables (1.09%).

7.1 Análisis de Costo-Beneficio

Transición	Ganancia Accuracy	Costo adicional	Veredicto
E1 → E2 (BiLSTM)	−0.46 pp (regresión)	×60 más tiempo, ×4 parámetros	No justificado
E1 → E3 (DistilBERT)	+3.01 pp	×60 más tiempo, ×132 parámetros	Justificado
E3 → E3 (RoBERTa-FT)	+1.80 pp adicionales	×2 parámetros, ×2.2 tiempo	Marginal
E3 → E5 LoRA	+0.17 pp (sobre E3)	−1.5M params entrenables	Muy eficiente

Conclusión de costo-beneficio: DistilBERT fine-tuned (Etapa 3) representa el mejor equilibrio del proyecto: ganancia significativa sobre el baseline con costo moderado. LoRA en la Etapa 5 es la estrategia más eficiente para producción: prácticamente mismo rendimiento que el fine-tuning completo con menos del 1.1% de los parámetros.

8. Diagrama del Sistema (Opcional)

8.1 Arquitectura del Sistema Completo

El sistema final integra los componentes de las cinco etapas en un pipeline unificado:

Pipeline del Chatbot Híbrido

Componente	Tecnología	Función	Etapa
Preprocesamiento	Python / regex	Limpieza de HTML, normalización	E1–E5
Tokenización	WordPiece (DistilBERT)	Sub-tokens, [CLS], [SEP], attention_mask	E3–E5
Clasificador	DistilBERT-base-uncased + LoRA	Detección de sentimiento binario	E3, E5
Generador	GPT-2 small (117M)	Respuesta empática condicionada	E4
Augmentación	T5-small (60M)	Paráfrasis de ejemplos difíciles	E4
Despliegue	Gradio	Interfaz web interactiva	E5

8.2 Evolución Arquitectónica

La progresión de arquitecturas refleja la evolución del campo NLP:

- Etapa 1: Representación dispersa (TF-IDF, 5K dimensiones) → clasificador lineal por capas densas
- Etapa 2: Embeddings densos entrenados (Word2Vec, 100d) → procesamiento secuencial recurrente (BiLSTM)
- Etapa 3: Embeddings contextuales preentrenados masivamente (DistilBERT, 768d) → atención global bidireccional
- Etapa 4: Sistema híbrido discriminativo-generativo: clasificador + modelo de lenguaje autoregresivo
- Etapa 5: Fine-tuning paramétrico eficiente (LoRA) + despliegue en interfaz web accesible

Cada transición supera una limitación concreta de la anterior. La BiLSTM captura orden pero no contexto masivo. DistilBERT captura contexto masivo pero no genera. GPT-2 genera pero requiere condicionamiento. LoRA optimiza eficientemente sin degradar el conocimiento preentrenado.

9. Conclusiones

El proyecto demostró exitosamente la viabilidad de construir un sistema completo de análisis de sentimientos y chatbot inteligente utilizando técnicas progresivas de Deep Learning sobre el dataset IMDb. Las conclusiones principales son:

- Los Transformers (DistilBERT) representan el salto cualitativo real del proyecto: no solo mejoran métricas (+3pp sobre baseline), sino que adquieren capacidad de manejar contexto, negaciones y dependencias de largo alcance que las arquitecturas anteriores no podían capturar
- La complejidad no siempre mejora el rendimiento: la BiLSTM con Word2Vec superó al baseline en capacidad representativa pero no en accuracy, evidenciando que para textos largos con vocabulario explícito, TF-IDF es extremadamente competitivo
- LoRA es la estrategia óptima para producción: con solo el 1.09% de parámetros entrenables, iguala el rendimiento del fine-tuning completo (92.27% vs 92.10%), minimizando el riesgo de catastrophic forgetting y el costo computacional
- El sarcasmo e ironía permanecen como el desafío técnico principal para los sistemas actuales de análisis de sentimientos, incluso con modelos Transformer preentrenados en corpus masivos
- GPT-2 sin fine-tuning de dominio produce respuestas diversas (Distinct-2=0.947) pero no siempre coherentes. El chatbot funciona correctamente en el 96.7% de los casos sin necesidad de recurrir a respuestas predefinidas

El objetivo del proyecto se cumplió completamente: se desarrolló un sistema funcional de cinco etapas que progresa desde un baseline clásico hasta un chatbot inteligente desplegado en Gradio, documentando rigurosamente cada decisión arquitectónica, sus justificaciones y sus limitaciones.