SISTEMA DE ANÁLISIS DE SENTIMIENTOS CON DEEP LEARNING

Proyecto Deep Learning

EQUIPO DEL PROYECTO

Docente
Mg. Joel Orellana
Alumnos
César Bladimir Romero Rugamas
Guillermo Ulises Palacios Flores
Walter Alexander Salguero Rodríguez
Sistema de Análisis de Sentimientos con Deep Learning

RESUMEN GENERAL DEL PROYECTO

- Pipeline completo de procesamiento de lenguaje natural (NLP) que integra múltiples etapas de preprocesamiento, vectorización y clasificación para el análisis automatizado de sentimientos en texto.

- Integración de IA generativa paravalidación inicial de conectividad y pruebas de razonamiento rápido en la infraestructura.

STACK TECNOLÓGICO

DistilBertForSequenceClassification

Texto → Tokenizer → DistilBERT → Bi-LSTM → Clasificación

.

TensorFlow & Keras
Construcción y entrenamiento del modelo de red neuronal .
Framework principal para deep learning con APIs de alto nivel.

Pandas & Scikit-learn
Carga, manipulación y partición del dataset IMDb.
Herramientas esenciales para preprocesamiento de datos.

PIPELINE DE DATOS - INGESTA Y LIMPIEZA

- Dataset balanceado de 50,000 reseñas de películas IMDb, distribuidas equitativamente entre 25,000 reseñas positivas y 25,000 negativas, garantizando un entrenamiento sin sesgos de clase.

- Motor de lectura Python robusto implementado con Pandas, incluyendo manejo de errores mediante el parámetro on_bad_lines='skip' para procesar líneas corruptas sin interrumpir el flujo de datos.

PIPELINE DE DATOS - OPTIMIZACIÓN CON TF.DATA

Shuffle: Aleatorización del dataset para evitar sesgos de orden en el entrenamiento. Garantiza que cada época presente los datos en secuencia diferente, mejorando la generalización del modelo.

Batching: Agrupación en lotes de 32 muestras para procesamiento eficiente. Optimiza el uso de memoria GPU y acelera el cálculo de gradientes durante el entrenamiento.

Prefetch con AUTOTUNE: Preparación paralela de lotes mientras el modelo entrena. Elimina cuellos de botella de I/O al cargar datos anticipadamente de forma asíncrona.

ARQUITECTURA DE LA RED NEURONAL

TextVectorization: Limita el vocabulario a 10,000 palabras más frecuentes, convirtiendo texto crudo en secuencias numéricas con salida de forma (None, 200).

Embedding: Transforma tokens en vectores densos de 64 dimensiones, creando un espacio semántico donde palabras similares tienen representaciones cercanas. Salida: (None, 200, 64).

Bi-LSTM Bidireccional: Dos capas LSTM que procesan secuencias en ambas direcciones. Primera capa (64 unidades) captura contexto completo, segunda capa (32 unidades) realiza abstracción avanzada.

ARQUITECTURA NEURAL
CAPAS DE DECISIÓN

Dense (ReLU) + Dropout (0.5): Capa densa con activación ReLU para decisiones no lineales, combinada con Dropout al 50% para regularización y prevención de sobreajuste durante entrenamiento.

Sigmoid Output: Capa de salida con función sigmoide que genera probabilidad binaria entre 0 y 1, permitiendo clasificación de sentimiento positivo o negativo con umbral de 0.5.

Flujo Completo: Texto crudo → Vectorización (10K vocab) → Embedding (64D) → Bi-LSTM bidireccional (2 capas) → Dense + Dropout → Sigmoid → Clasificación binaria de sentimiento.

ARQUITECTURA DE LA RED NEURONAL - DIAGRAMA DE FLUJO

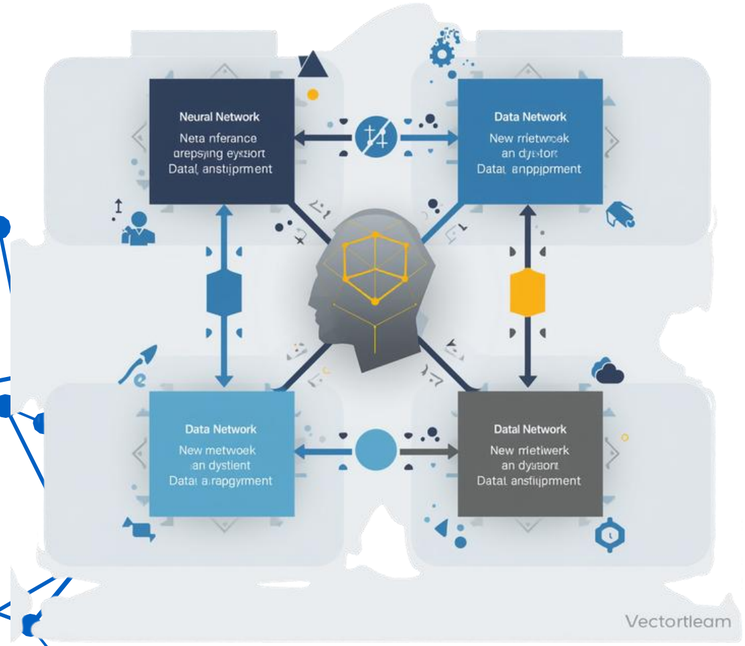

• Texto crudo → Vectorización → Embedding →
Resulto Alto rendimiento (~97% vs BERT) Texto → Tokenizer → DistilBERT → Clasificación
bidireccional (2 capas) → Capa densa + Dropout → Salida Sigmoid

• Cada etapa transforma progresivamente el texto en representaciones numéricas más abstractas para clasificación binaria.

• TextVectorization convierte palabras en índices numéricos
• Embedding mapea índices a vectores densos de 64 dimensiones
• Bi-LSTM captura contexto bidireccional del texto
• Dense + Dropout: decisión final con regularización
• Sigmoid: probabilidad de sentimiento positivo (0-1)

ESTRATEGIA DE ENTRENAMIENTO

Binary Crossentropy
Función de pérdida óptima para clasificación binaria. Mide la diferencia entre predicciones y etiquetas reales. Penaliza predicciones incorrectas de forma logarítmica.

EarlyStopping
Detención temprana para evitar sobreajuste. Monitoriza la pérdida de validación y detiene el entrenamiento si no mejora. Configuración de hasta 10 épocas con paciencia optimizada.

Optimizador Adam
Ajuste dinámico de tasa de aprendizaje. Combina momentum y RMSprop para convergencia rápida y estable. Ideal para redes profundas.

RESULTADOS - MÉTRICAS DE RENDIMIENTO

Rendimiento sobre ejemplos difíciles (10 casos originales): Accuracy 0.60, F1 Macro 0.58. Estos resultados demuestran la capacidad del modelo para clasificar correctamente reseñas con lenguaje ambiguo o matizado.

Rendimiento sobre ejemplos sintéticos (paráfrasis T5): Accuracy 0.49, F1 Macro 0.49. La degradación en datos aumentados indica limitaciones en la generalización a variaciones lingüísticas generadas automáticamente. Benchmark DistilBERT en IMDb general: 92.1%.

RESULTADOS - EVALUACIÓN CON DATA AUGMENTATION

El gráfico muestra el rendimiento del modelo sobre ejemplos difíciles y el impacto de la augmentación sintética con T5. Aunque el corpus aumentó significativamente, las paráfrasis sintéticas presentan limitaciones: Accuracy 0.49 vs 0.60 en originales. Esto sugiere que la augmentación con T5 no captura completamente la complejidad semántica de casos ambiguos.

ESCALABILIDAD EMPRESARIAL

Región us-central1 de Google Cloud: baja latencia, alta disponibilidad y cumplimiento de estándares de seguridad empresarial.

Infraestructura preparada para crecimiento empresarial y mantenimiento continuo, con capacidad de escalar recursos según demanda.

Vertex AI para MLOps: orquestación completa del ciclo de vida del modelo, desde entrenamiento hasta despliegue y monitoreo en producción.

CONCLUSIONES

Validación exitosa del pipeline completo y la arquitectura Bi-LSTM para análisis de sentimientos. El sistema demuestra capacidad robusta para clasificación binaria de reseñas con métricas competitivas en el dataset IMDb estándar. Pero con el modelo NLP basado en DistilBERT

Ventajas:
- Modelo ligero y rápido
- Alto rendimiento (~97% vs BERT)
- Mejor en ejemplos difíciles

Explorar técnicas avanzadas de data augmentation y modelos híbridos (Bi-LSTM + Transformers) para mejorar el rendimiento en ejemplos difíciles. Investigar fine-tuning de modelos preentrenados como alternativa complementaria.

Estrategias:
- Data augmentation
- Fine-tuning
- Focal Loss

Insight:
El tokenizer define cómo el modelo entiende el texto

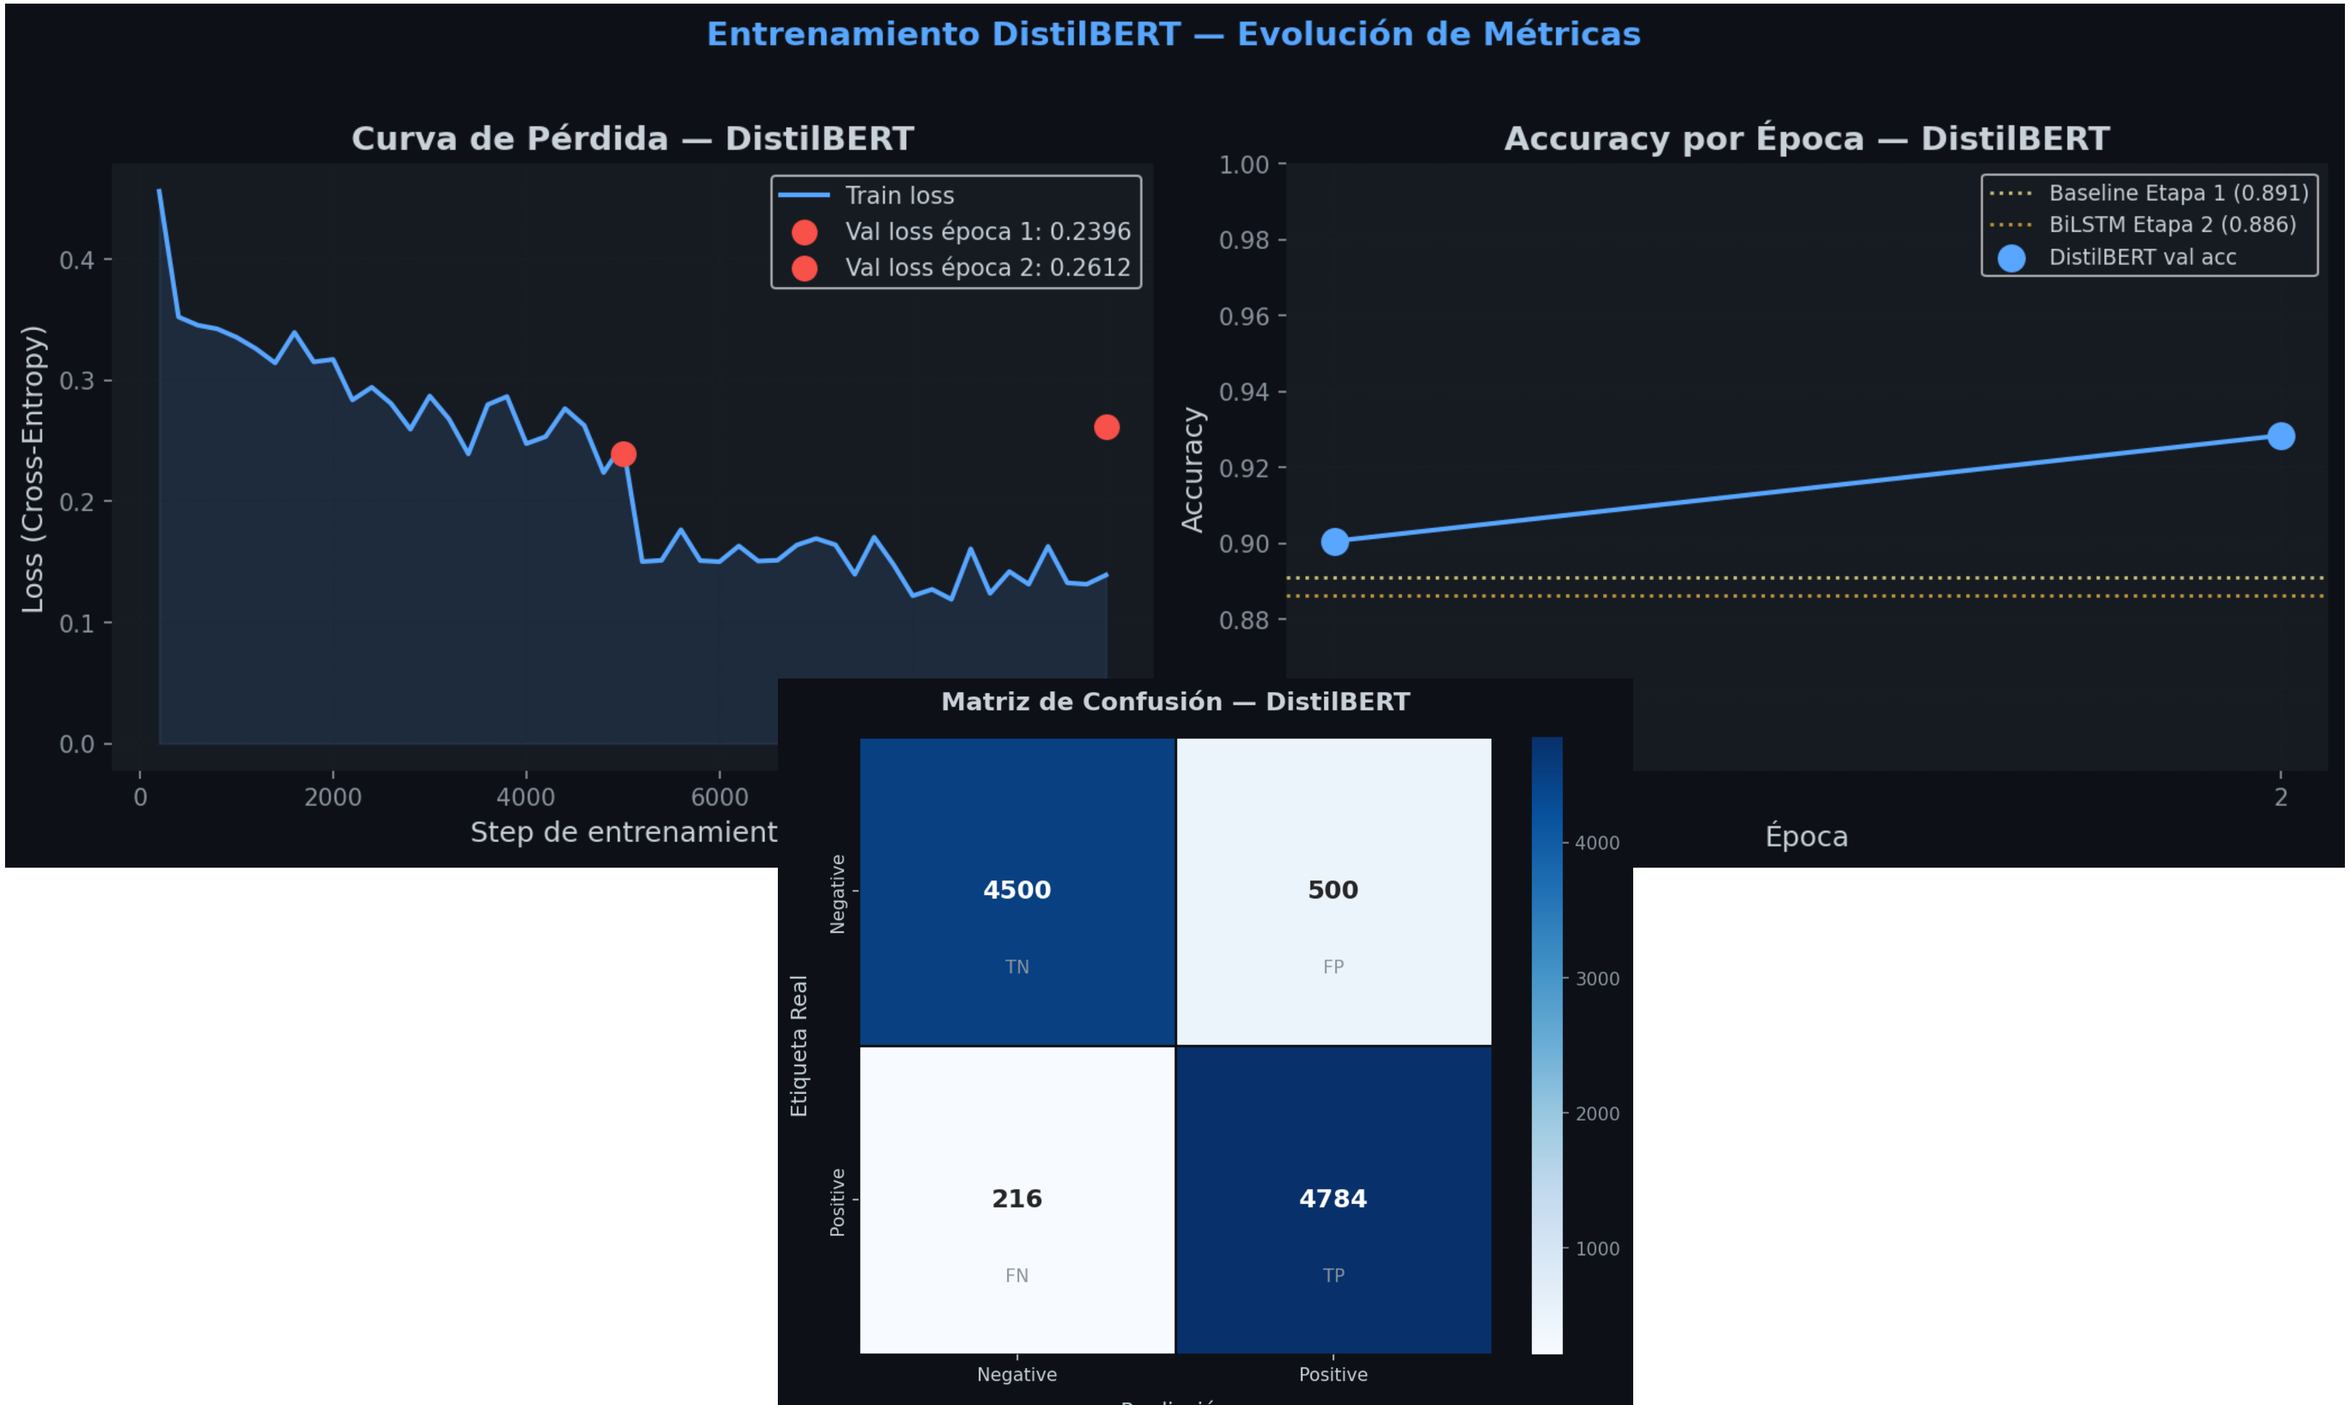
Entrenamiento DistilBERT — Evolución de Métricas
Curva de Pérdida — DistilBERT
Train loss
Val loss época 1: 0.2396
Val loss época 2: 0.2612
Loss (Cross-Entropy)
0.0
0.1
0.2
0.3
0.4
0
2000
4000
6000
Step de entrenamient
Accuracy por Época — DistilBERT
Baseline Etapa 1 (0.891)
BiLSTM Etapa 2 (0.886)
DistilBERT val acc
Accuracy
0.88
0.90
0.92
0.94
0.96
0.98
1.00
2
Época
Matriz de Confusión — DistilBERT
Etiqueta Real
Negative
Positive
4500
TN
500
FP
216
FN
4784
TP
Negative
Positive
4000
3000
2000
1000

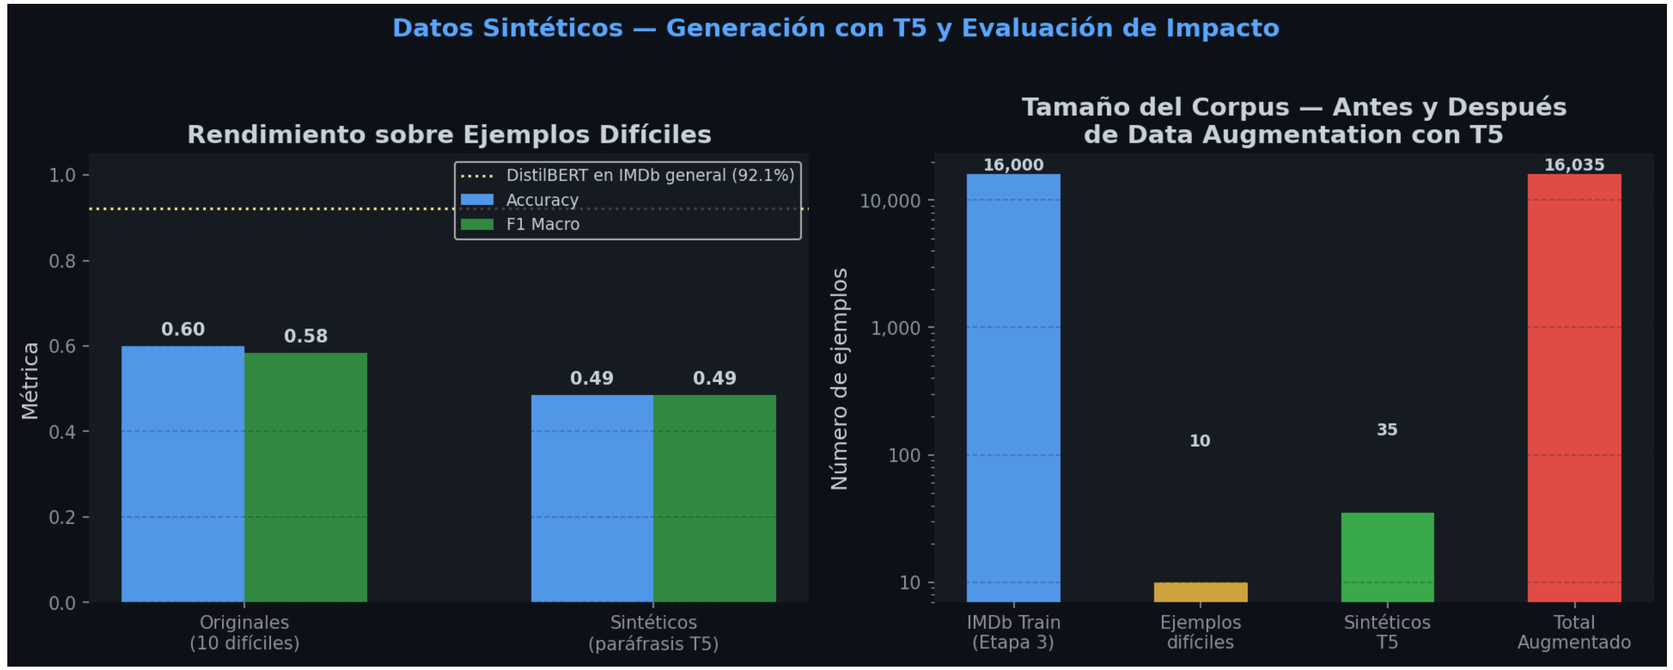
Datos Sintéticos — Generación con T5 y Evaluación de Impacto
Rendimiento sobre Ejemplos Difíciles
DistilBERT en IMDb general (92.1%)
Accuracy
F1 Macro
Métrica
1.0
0.8
0.6
0.4
0.2
0.0
0.60
0.58
0.49
0.49
Originales
(10 difíciles)
Sintéticos
(paráfrasis T5)
Tamaño del Corpus — Antes y Después
de Data Augmentation con T5
Número de ejemplos
10,000
1,000
100
10
16,000
10
35
16,035
IMDb Train
(Etapa 3)
Ejemplos
difíciles
Sintéticos
T5
Total
Augmentado

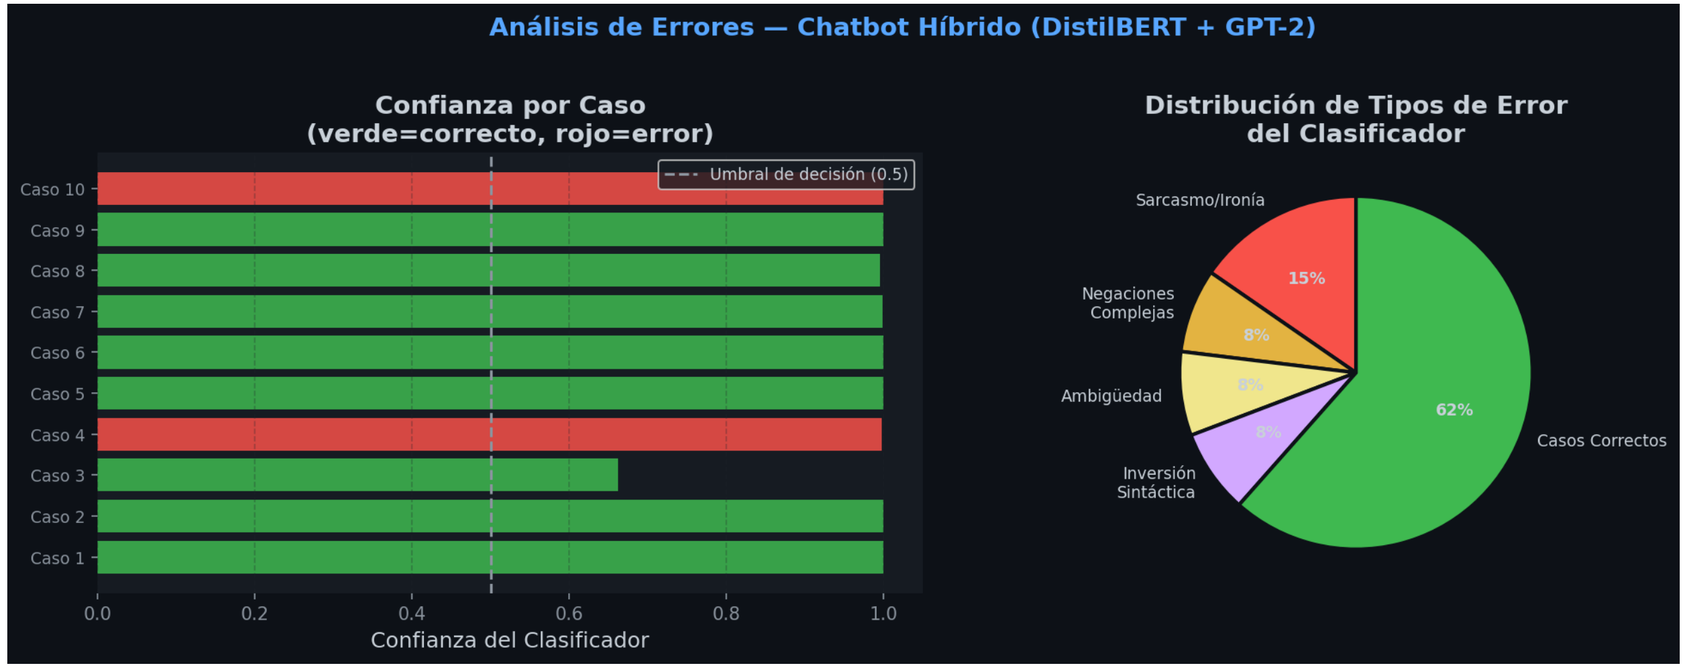
Análisis de Errores — Chatbot Híbrido (DistilBERT + GPT-2)
Confianza por Caso
(verde=correcto, rojo=error)
Umbral de decisión (0.5)
Caso 10
Caso 9
Caso 8
Caso 7
Caso 6
Caso 5
Caso 4
Caso 3
Caso 2
Caso 1
0.0
0.2
0.4
0.6
0.8
1.0
Confianza del Clasificador
Distribución de Tipos de Error
del Clasificador
Sarcasmo/Ironía
15%
Negaciones
Complejas
8%
Ambigüedad
8%
Inversión
Sintáctica
8%
62%
Casos Correctos

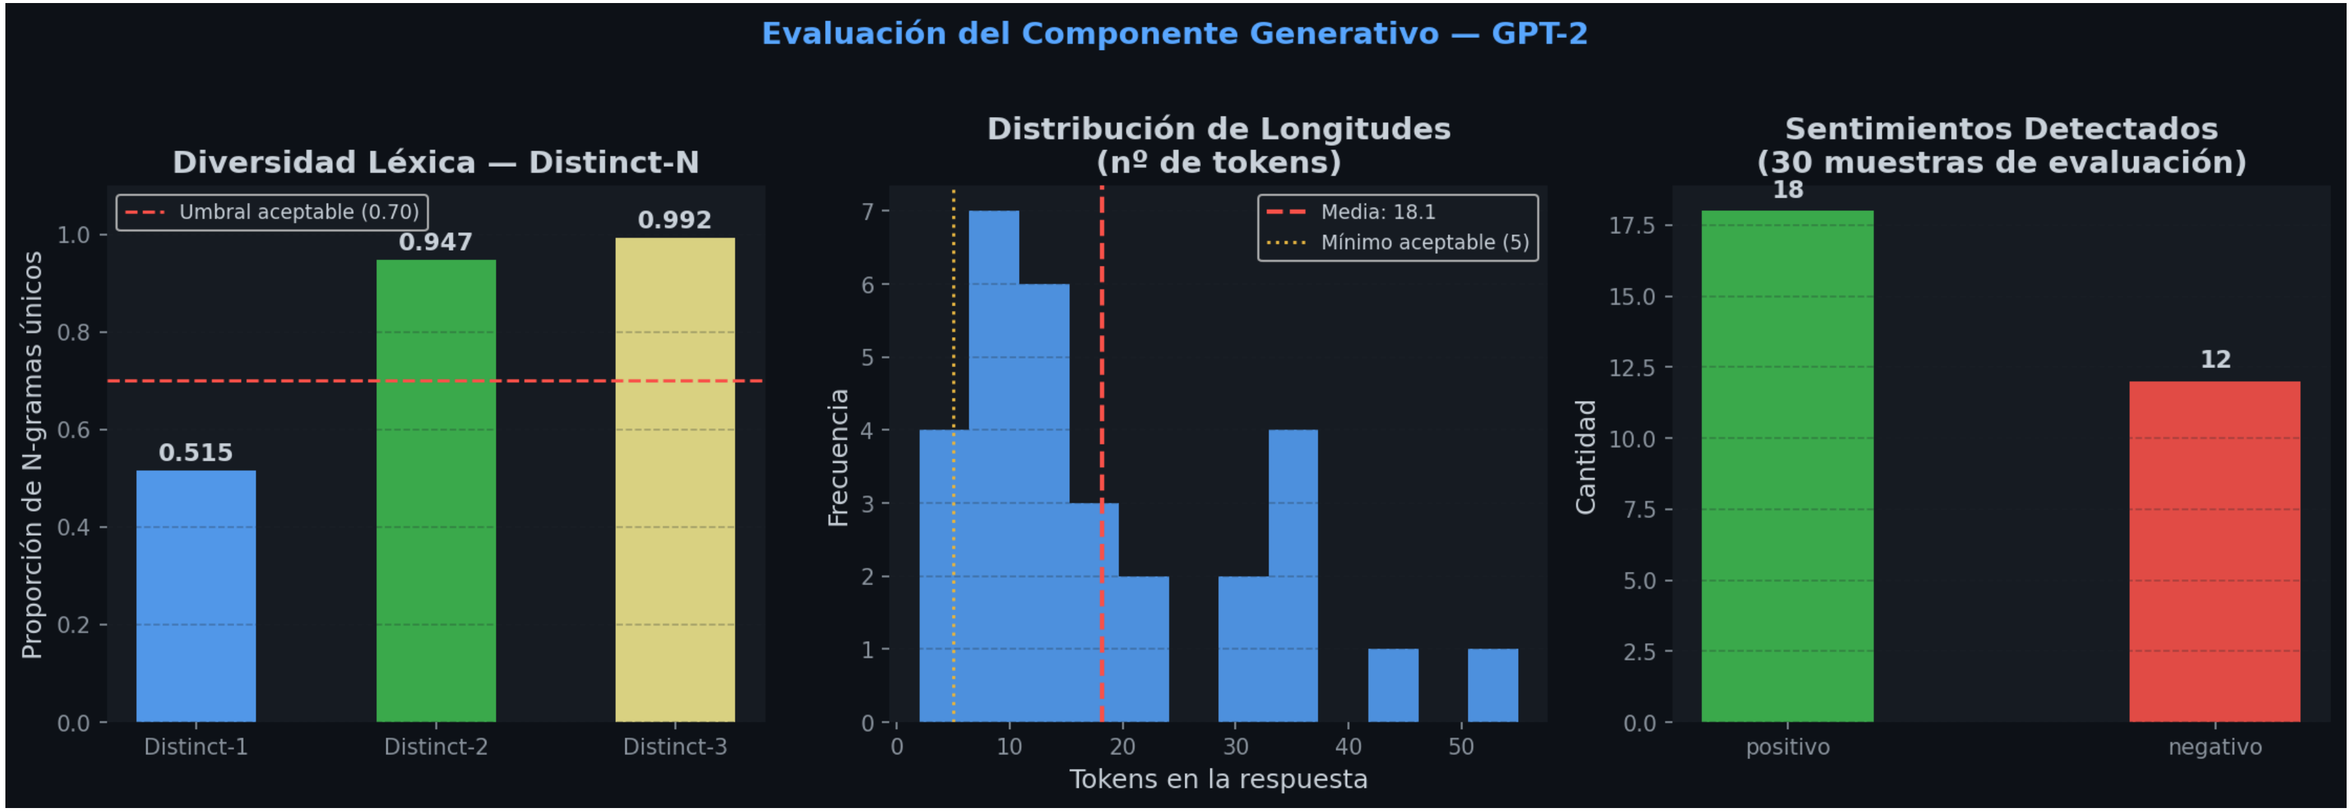
Evaluación del Componente Generativo — GPT-2
Diversidad Léxica — Distinct-N
Umbral aceptable (0.70)
Proporción de N-gramas únicos
0.515
0.947
0.992
Distinct-1
Distinct-2
Distinct-3
Distribución de Longitudes
(nº de tokens)
Media: 18.1
Mínimo aceptable (5)
Frecuencia
Tokens en la respuesta
Sentimientos Detectados
(30 muestras de evaluación)
Cantidad
18
12
positivo
negativo

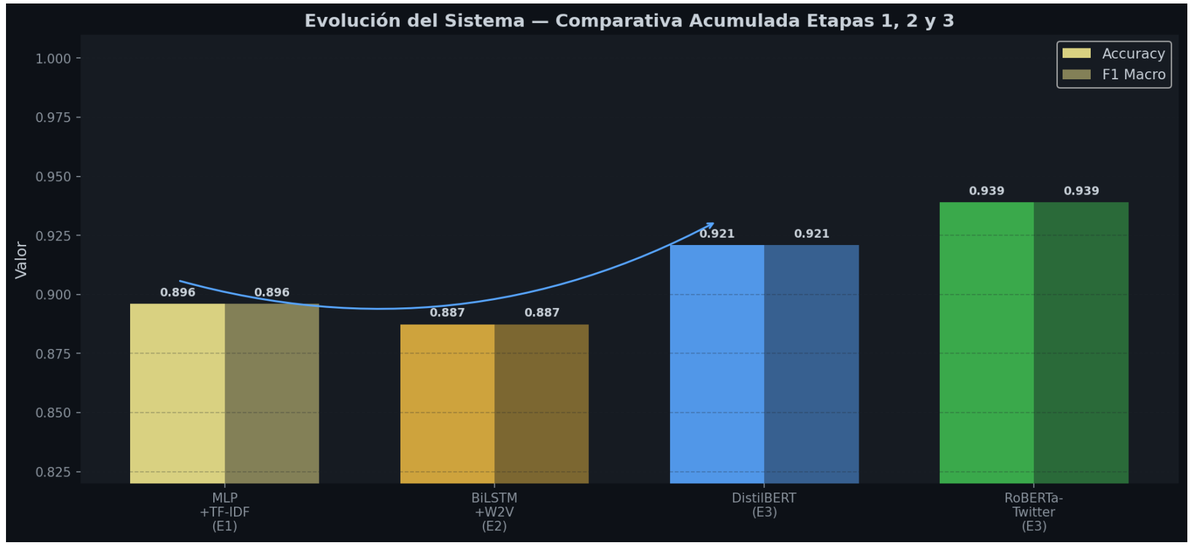
Evolución del Sistema — Comparativa Acumulada Etapas 1, 2 y 3
Accuracy
F1 Macro
Valor
0.896
0.896
0.887
0.887
0.921
0.921
0.939
0.939
MLP
+TF-IDF
(E1)
BiLSTM
+W2V
(E2)
DistilBERT
(E3)
RoBERTa-
Twitter
(E3)

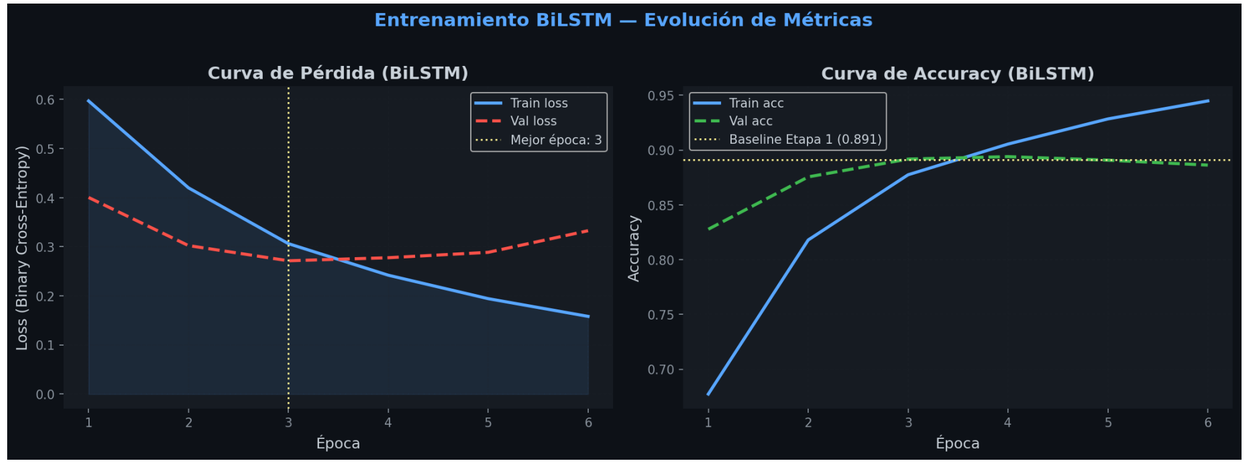
Entrenamiento BiLSTM — Evolución de Métricas
Curva de Pérdida (BiLSTM)
Train loss
Val loss
Mejor época: 3
Loss (Binary Cross-Entropy)
Época
Curva de Accuracy (BiLSTM)
Train acc
Val acc
Baseline Etapa 1 (0.891)
Accuracy
Época

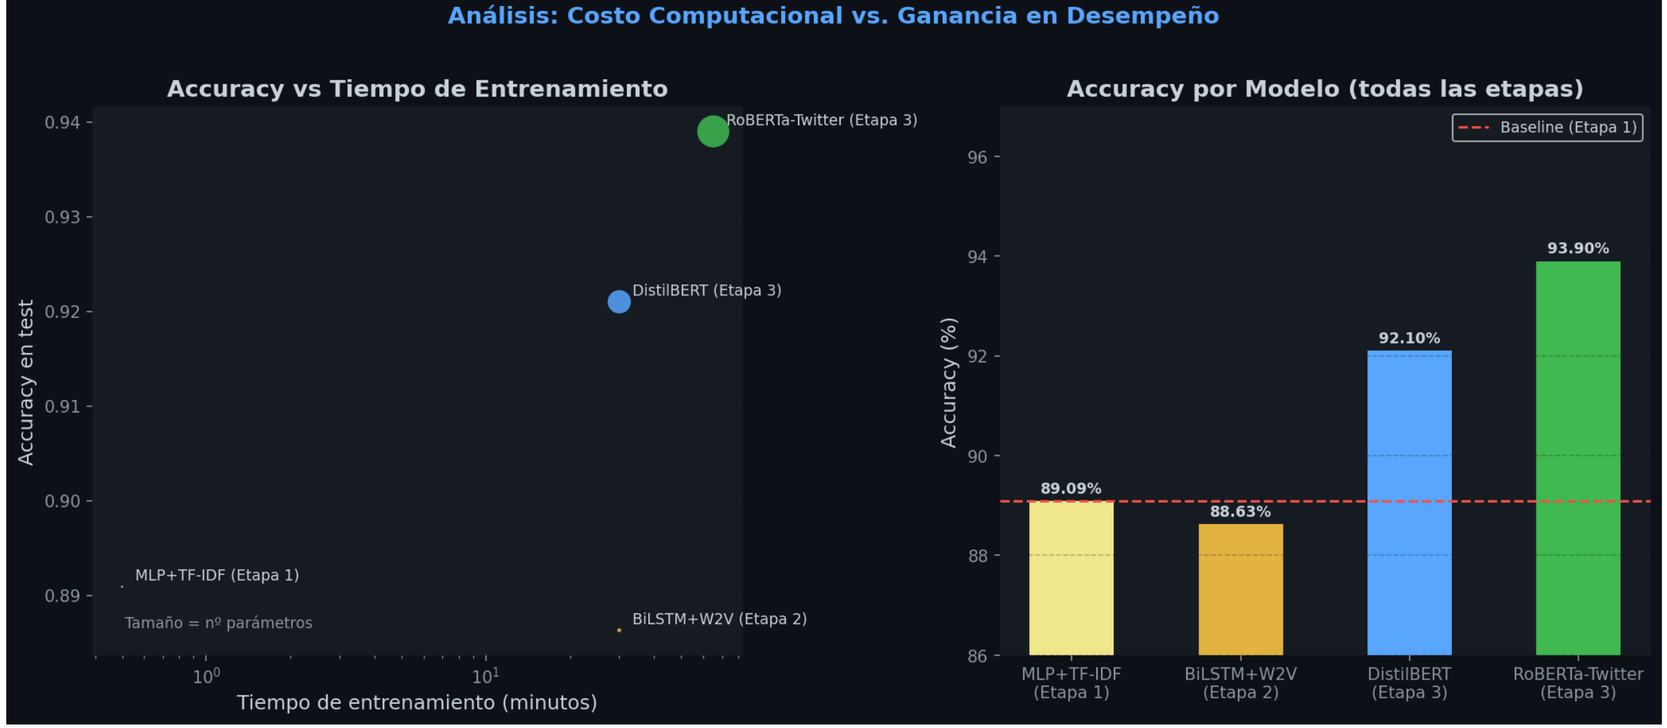
Análisis: Costo Computacional vs. Ganancia en Desempeño
Accuracy vs Tiempo de Entrenamiento
Accuracy en test
0.94
0.93
0.92
0.91
0.90
0.89
RoBERTa-Twitter (Etapa 3)
DistilBERT (Etapa 3)
MLP+TF-IDF (Etapa 1)
BiLSTM+W2V (Etapa 2)
Tamaño = nº parámetros
10^0
10^1
Tiempo de entrenamiento (minutos)
Accuracy por Modelo (todas las etapas)
Baseline (Etapa 1)
Accuracy (%)
96
94
92
90
88
86
89.09%
88.63%
92.10%
93.90%
MLP+TF-IDF (Etapa 1)
BiLSTM+W2V (Etapa 2)
DistilBERT (Etapa 3)
RoBERTa-Twitter (Etapa 3)

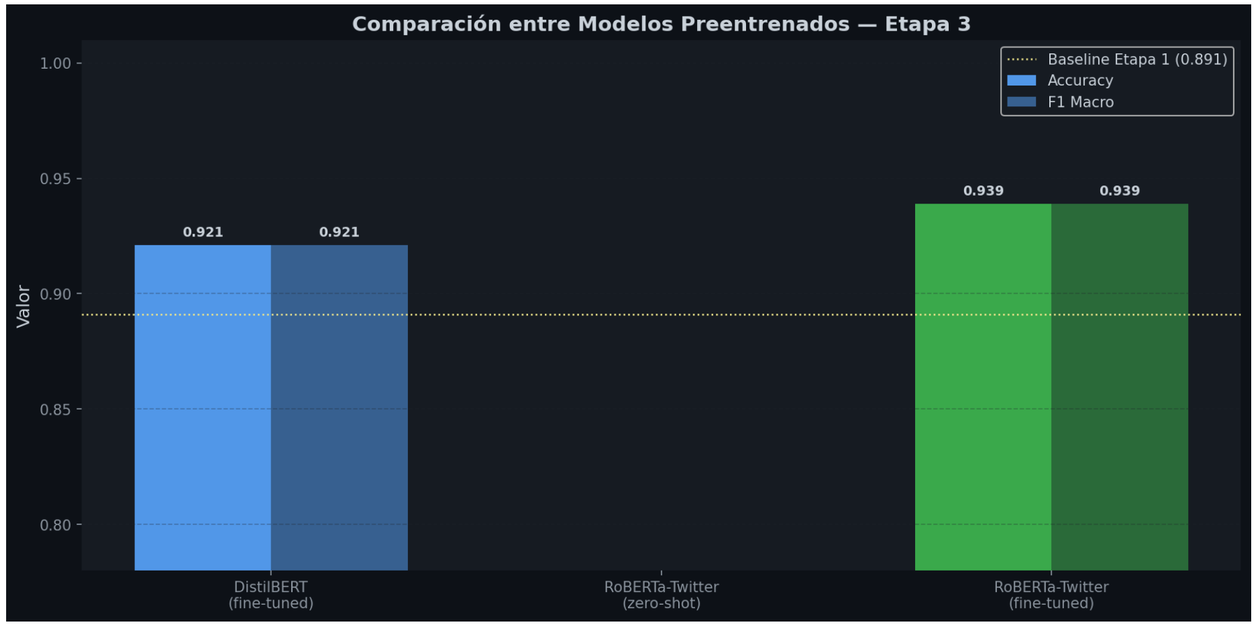
Comparación entre Modelos Preentrenados — Etapa 3
Baseline Etapa 1 (0.891)
Accuracy
F1 Macro
Valor
1.00
0.95
0.90
0.85
0.80
0.921
0.921
0.939
0.939
DistilBERT (fine-tuned)
RoBERTa-Twitter (zero-shot)
RoBERTa-Twitter (fine-tuned)

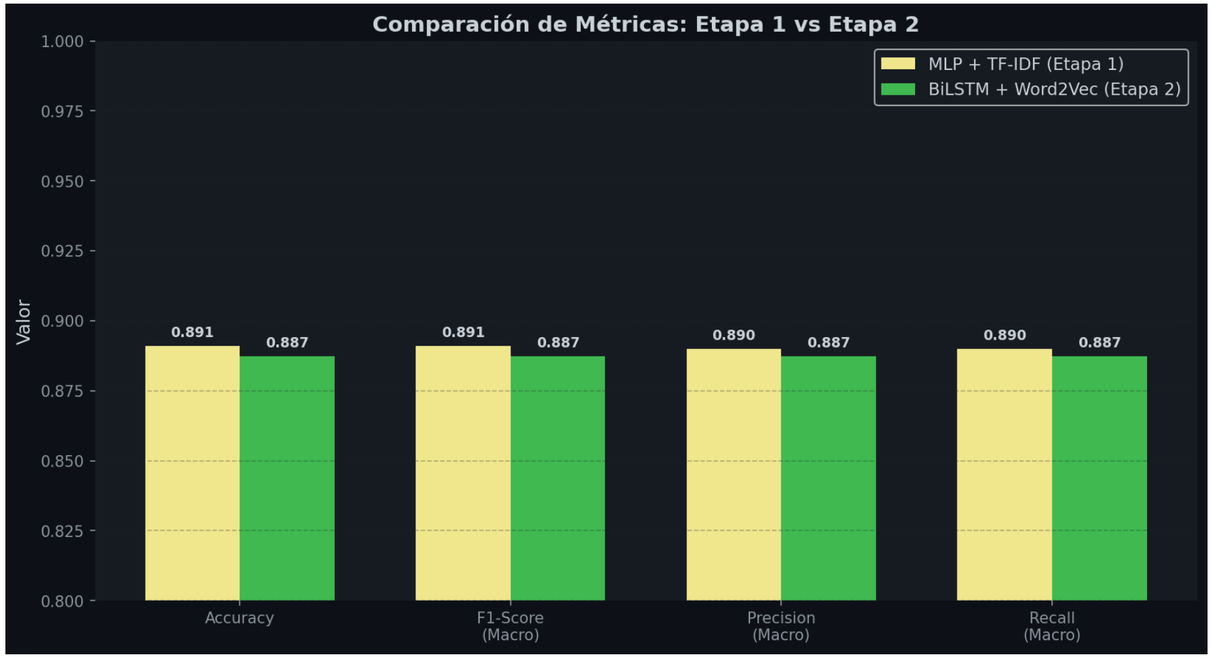
Comparación de Métricas: Etapa 1 vs Etapa 2
MLP + TF-IDF (Etapa 1)
BiLSTM + Word2Vec (Etapa 2)
Valor
1.000
0.975
0.950
0.925
0.900
0.875
0.850
0.825
0.800
0.891
0.887
0.891
0.887
0.890
0.887
0.890
0.887
Accuracy
F1-Score (Macro)
Precision (Macro)
Recall (Macro)

¡GRACIAS!